Breast-Cancer-Classification-ML-Study
ML Eng. Mahmoud Ali Souliman
Mahmoud.a.souliman@Gmail.com

مقدمة عامة حول المشروع

عنوان المشروع:
مقارنة وتحليل أداء خمس خوارزميات تصنيف على مجموعة بيانات Wisconsin Breast Cancer **لتشخيص الأورام.**
Comparison and analysis of the performance of five classification algorithms on the Wisconsin Breast Cancer dataset for tumor diagnosis.

ملخص المشروع:
يهدف هذا المشروع إلى استكشاف وتقييم قدرة خوارزميات التعلم الآلي على التمييز بين الأورام الخبيثة (Malignant)والحميدة (Benign) لسرطان الثدي بناءً على 30 خاصية مميزة (Features) مستخلصة من صور الأنسجة. سيتم مقارنة أداء كل من الانحدار اللوجستي(LR) ، والمنحدَر الساذج(NB) ، وشجرة القرار (DT)، وآلة المتجهات الداعمة(SVM) ، وأقرب الجيران(KNN) ، مع التركيز على المقاييس الحيوية للتطبيقات الطبية.

نبذة عن مجموعة البيانات المستخدمة:
الاسم العلمي:
Breast cancer Wisconsin (diagnostic) dataset
المزود: sklearn
عدد الحالات: 569 حالة (212 خبيث- 357 حميد).
السمات Features: 30 سمة رقمية تصف الخصائص النووية والخلوية للخلايا (مثل متوسط نصف القطر، نسيج الصورة، إلخ).
الأهداف Targets : ثنائي (0: حميد، 1: خبيث).

التقنيات المستخدمة:
ستتم البرمجة والاختبار على Colab.

الجسم الرئيسي للمشروع

سنقوم بعرض هذا التقرير بما يتلاءم مع تسلسل المهمات المطلوبة في ملف المشروع.

المهمة الأولى:

تتلخص باستيراد مجموعة البيانات والمكتبات اللازمة لتنفيذ المشروع والكشف عن وجود قيم مفقودة وبعد ذلك خطوة مهمة تتمثل في تسوية البيانات.

توصيف البيانات:

تعتمد مجموعة بيانات Wisconsin Breast Cancer (WBC) على تحليل رقمي لصور الشفط بالإبرة الدقيقة(FNAC) ، حيث يتم قياس الخصائص النووية والخلوية للخلايا السرطانية. تتكون مجموعة البيانات من 30 سمة رقمية(Features) ، تمثل في الواقع 10خصائص أساسية، حيث تُحسب كل خاصية بثلاثة أشكال إحصائية:

Mahmoud Ali Souliman

المتوسط Mean: يمثل القيمة المتوسطة للميزة عبر الصورة.
الخطأ المعياري Standard error: يمثل التباين أو مدى عدم اليقين في قياس الميزة.
الأسوأ Worst: يمثل أسوأ أو أكبر قيمة تم قياسها للميزة (غالبًا ما يكون مؤشراً قوياً على الخباثة).
الخصائص الأساسية ال 10 المقاسة من قبل العلماء والتي تعتبر الأكثر أهمية:

الخاصية	دلالتها في التشخيص	الوصف المبسط
نصف القطر radius	تشير الخلايا ذات نصف القطر الأكبر إلى أورام أكثر عدوانية.	**متوسط المسافات من مركز الخلية إلى النقاط على المحيط.**
النسيج texture	يصف خشونة سطح الورم أو عدم انتظام النسيج.	**تباين تدرجات اللون الرمادي في الصورة.**
المحيط perimeter	عادة الخلايا الورمية ذات محيط كبير	**محيط النواة الخلوية أو حدود الورم.**
المساحة Area	مقياس لحجم الخلية أو الكتلة.	**مساحة النواة الخلوية أو الورم.**
النعومةsmoothness	تشير الحدود غير المنتظمة (الخشونة) إلى الخباثة.	**التباين المحلي في أطوال نصف القطر حول المحيط.**
التراص compactness	يصف مدى تناسق شكل الخلية؛ الخلايا غير المدمجة (أقل تراصاً) قد تكون خبيثة.	**مقياس لمقارنة المحيط والمساحة (الـ Perimeter2/Area).**
التقعر concavity	**الخلايا الخبيثة تظهر تقعرات وانبعاجات أكثر وضوحاً.**	**شدة وعدد الانبعاجات أو التجويفات المقعرة في محيط الخلية.**
النقاط المقعرة concave points	مقياس مباشر لعدوانية الخلايا (مؤشر قوي على الخباثة).	**عدد الأجزاء المقعرة من المحيط.**
التناظر symmetry	الخلايا غير المتناظرة (أقل تناظراً) ترتبط بالأورام الخبيثة.	**مدى انتظام شكل الخلية.**
الأبعاد الكسرية Fractional dimensions	الخلايا الخبيثة تكون أكثر تعقيداً في الشكل (بعد كسري أعلى).	**مقياس لمدى تعقيد وتفاصيل الحدود.**

باللون الأحمر وضعنا الخاصية الأكثر ارتباطاً بتصنيف الورم الخبيث وهي (التقعر concavity) والشكل الاحصائي المرتبط بالخباثة (عندما يكون ملحقاً بسمة ما) وهو (أسوأ قياس Worst).
الإحصاءات الوصفية المرتبطة بالسمات features الخاصة بمجموعة البيانات التي سنستخدمها:
في الجدول اللاحق سنستعرض الخواص الوصفية مع الحد الأدنى min والحد الأقصى max للسمات كما أوردها دليل المستخدم user manual الخاص بمجموعة البيانات:

FEATURE	MEASURE	MINIMUM VALUE (MIN)	MAXIMUM VALUE (MAX)
RADIUS	Mean	6.981	28.11
TEXTURE	Mean	9.71	39.28
PERIMETER	Mean	43.79	188.5
AREA	Mean	143.5	2501
SMOOTHNESS	Mean	0.053	0.163
COMPACTNESS	Mean	0.019	0.345
CONCAVITY	Mean	0	0.427
CONCAVE POINTS	Mean	0	0.201
SYMMETRY	Mean	0.106	0.304
FRACTAL DIMENSION	Mean	0.05	0.097
---	---	---	---
RADIUS	Standard Error	0.112	2.873

Mahmoud Al-Sumrah

TEXTURE	Standard Error	0.36	4.885
PERIMETER	Standard Error	0.757	21.98
AREA	Standard Error	6.802	542.2
SMOOTHNESS	Standard Error	0.002	0.031
COMPACTNESS	Standard Error	0.002	0.135
CONCAVITY	Standard Error	0	0.396
CONCAVE POINTS	Standard Error	0	0.053
SYMMETRY	Standard Error	0.008	0.079
FRACTAL DIMENSION	Standard Error	0.001	0.03
RADIUS	Worst	7.93	36.04
TEXTURE	Worst	12.02	49.54
PERIMETER	Worst	50.41	251.2
AREA	Worst	185.2	4254
SMOOTHNESS	Worst	0.071	0.223
COMPACTNESS	Worst	0.027	1.058
CONCAVITY	Worst	0	1.252
CONCAVE POINTS	Worst	0	0.291
SYMMETRY	Worst	0.156	0.664
FRACTAL DIMENSION	Worst	0.055	0.208
SOURCES			

الملاحظة الأساسية في البيانات هي الفروقات الهائلة في المقاييس بين السمات المختلفة ومثال على ذلك:

السمات ذات النطاق الضيق(Narrow Range)	السمات ذات النطاق الواسع(Wide Range)
Smoothness (النعومة): (Mean Max = 0.163)	Area (المساحة): (Mean Max = 2501.0)
Fractal Dimension (البعد الكسري): (Mean Max = 0.097)	Perimeter (المحيط): (Mean Max = 188.5)

في هذين المثالين نلاحظ الفروقات في القيم بين السمات وهنا لدينا مشكلة كبيرة إذ ستسيطر السمات ذات القيم الكبيرة على أداء الشبكة العصبية الصناعية وخصوصاً عند استخدام خوارزميات مثل خوارزميات الجيران الأقرب k-nearest neighbors وخوارزميات آلة شعاع الدعم SVM. إذا لا بد من معالجة هذه المشكلة قبل البدء بتدريب الشبكة.

معالجة المشاكل المرتبطة بالبيانات:

بالنسبة **للقيم المفقودة** لا يوجد لدينا قيم مفقودة في تسجيلات مجموعة البيانات (كما هو موجود في دليل المستخدم الخاص بمجموعة البيانات) ولا حاجة للقيام بأي عملية بهذا الصدد. مع ذلك قمنا بإضافة خلية في colab للتحقق من ذلك وكانت النتيجة سلبية (لا يوجد قيم فارغة).

ولكن من أهم عمليات المعالجة المسبقة لهذه البيانات هي **عملية تقييس قيم السمات** والتي سنقوم بها مباشرة باستخدام الصف StandardScalar في الصورة التالية سنورد قيم الانحراف المعياري لأول 5 تسجيلات قبل وبعد تطبيق التسوية أو التقييس:

Mahmoud Ali Sulima

```
The  standard deviation before standardization or normalization
 mean radius          3.524049
mean texture         4.301036
mean perimeter      24.298981
mean area          351.914129
mean smoothness      0.014064
dtype: float64
The  standard deviation after standardization or normalization
 mean radius        1.00088
mean texture       1.00088
mean perimeter     1.00088
mean area          1.00088
mean smoothness    1.00088
dtype: float64
```

Figure 1الانحراف المعياري قبل وبعد التقييس والتسوية

بالنسبة للمتوسط الحسابي لقيم السمات قبل وبعد التقييس سنظهرها في الجدول التالي:

```
The mean before standardization or normalization
 mean radius          14.127292
mean texture         19.289649
mean perimeter       91.969033
mean area           654.889104
mean smoothness       0.096360
dtype: float64
The mean after standardization or normalization
 mean radius        -3.162867e-15
mean texture       -6.530609e-15
mean perimeter     -7.078891e-16
mean area          -8.799835e-16
mean smoothness     6.132177e-15
```

Figure 2المتوسط الحسابي للقيم قبل وبعد التقييس

نلاحظ كيف نجح الصف StandardScalar بتسوية وتطبيع قيم السمات المختلفة لضمان عدم تأثر الخوارزميات بالقيم المتطرفة، حيث أصبح الانحراف المعياري قريباً من ال 1 والمتوسط قريباً من 0 وهكذا تكون البيانات بحالة ممتازة للبدء في العمل.

توازن البيانات Data Balancing: في مسائل التصنيف بشكل عام لا بد من القيام بعملية توازن للبيانات وهي عملية تهدف لحل مشكلة عدم تساوي الأمثلة (الحالات الطبية) التي تمثل الحالة الخبيثة وهي ذات عدد أقل، مع الأمثلة التي تمثل الحالات الحميدة والتي عددها أكبر، مما يجعل الشبكة تنحاز إلى صنف مجموعة البيانات الأكبر.

في مسألتنا لا يوجد فرق كبير بين الأمثلة التي تم تصنيفها (من قبل العلماء) على أنها خبيثة (37.3 %من الأمثلة خبيثة) والأمثلة التي صنفها العلماء على أنها حميدة (62.7% من الأمثلة حميدة). لذلك قررنا اسقاط عملية موازنة البيانات والقبول بالتوازن الحالي للبيانات الموجود فعلياً ومقارنة أداء الخوارزميات الخمسة تحت هذا التوازن.

المهمة الثانية والثالثة:

بما أننا سنعتمد على مكتبة sklearn في تنفيذ الخوارزميات قمنا بدمج المهمتين 2 و3 في التنفيذ، وذلك للتركيز على مهمتنا في المقارنة بين هذه الخوارزميات في المهمات اللاحقة.

تتمثل المهمة الثانية في تنجيز الخوارزميات الخمس المطلوبة لمقارنة أداء كل خوارزمية على نفس مجموعة البيانات بعد عمليات التسوية والتطبيع لهدف دراسة أداء كل منها وهذه الخوارزميات هي:

- خوارزمية الانحدار اللوجيستي.
- خوارزمية بايز.
- خوارزمية أشجار القرار.
- خوارزمية آلة شعاع الدعم.
- خوارزمية الجيران الأقرب.

في التنفيذ العملي في Colab قمنا بتقسيم هذه الخطوة إلى عدة خلايا وذلك لسببين:

1. وجود عمليان مشتركة بين الخوارزميات الخمسة، وهي عملية استيراد المكتبات وتقسيم البيانات بشكل أساسي.
2. هدفنا الأساسي في مشروعنا هو تقييم فروقات الأداء بين الخوارزميات المختلفة لذلك سنقوم بعملية تقسيم البيانات (اختبار – تدريب) خارج جسم الحلقة التي ستدرب الخوارزميات لنضمن أن جميع الخوارزميات استخدمت نفس البيانات في عملية التصنيف، بذلك سيكون الحكم فقط على أداء الخوارزمية.

عملية الinitialization للخوارزميات الخمسة:

سنقوم من خلال إنشاء dictionary بإعداد الخوارزميات الخمسة وضبط البارامترات الأساسية الخاصة بكل خوارزمية، وسنقوم بالنسبة لخوارزمية الSVM باختيار الوضع true للسمة probabilityلحساب استقراء احتمالي لاستخدامه في المهمات اللاحقة (رسم المنحنيات)، بالنسبة لخوارزمية الKNN اخترنا عدد الجيران الأقرب 10 جيران كونها قيمة متناسبة مع طبيعة المسألة وعدد التسجيلات في مجموعة البيانات.

```
models = {
    "Logistic Regression": LogisticRegression(random_state=42),
    "Naive Bayes": GaussianNB(),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "Support Vector Machine (SVM)": SVC(probability=True, random_state=42),
    "k-Nearest Neighbors (KNN)": KNeighborsClassifier(n_neighbors=10)
}
```

Figure 3إنشاء قاموس dictionary لإعداد الخوارزميات الخمسة

Mahmoud Soliman

عملية التدريب للخوارزميات الخمسة:

في عملية التدريب سنستخدم حلقة تكرارية للمرور على القاموس الذي تم إنشاؤه سابقاً وتدريب كل خوارزمية على حدي وحفظ النماذج المدربة في قاموس جديد، تظهر الصورة أدناه خلية Colab الموافقة لعملية التدريب:

```
trained_models = {}
for name, model in models.items():
    print(f"TRAINING MODEL: {name}...")
    model.fit(X_train, y_train)
    trained_models[name] = model
    print(f"TRAINING COMPLETE : {name}.\n")
print("All classifiers trained!")
```

Figure 4 تدريب النماذج عن طريق حلقة تكرارية وحفظ النماذج المدربة في dictionary

عملية حساب معايير الأداء لتقييم للخوارزميات الخمسة:

عن طريق حلقة تكرارية سنقوم بحساب معايير تقييم الأداء لكل خوارزمية على حدى، وحفظ هذه النتائج بقائمة وعرضها.

```
results = []
for name, model in trained_models.items():
    y_pred = model.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    precision = precision_score(y_test, y_pred)
    recall = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)

    results.append({
        "Algorithm": name,
        "Accuracy": accuracy,
        "Precision": precision,
        "Recall": recall,
        "F1-Score": f1
    })
```

Figure 5 حساب معايير تقييم الأداء

خصوصية معايير تقييم الأداء المختلفة بالنسبة لمسائل التصنيف الطبي:

في مسائل التصنيف الطبي لدينا معيارين لهما اعتبارات خاصة وهما ال precision والRecall لماذا:

Precision: يوضح مدى موثوقية النموذج في تنبؤاته الإيجابية (إصدار تنبؤ بوجود مرض) .إذا كان مرتفعاً ومستقراً :فهذا يعني أن النموذج نادراً ما يعطي نتائج إيجابية خاطئة False Positive.

Recall: مدى قدرة النموذج على اكتشاف جميع الحالات الإيجابية (الأشخاص المرضى) .إذا كان مرتفعاً ومستقراً :فهذا يعني أن النموذج نادراً ما يعطي نتائج سلبية خاطئةFalse Negative .

في الجدول أدناه نتائج حساب معايير تقييم الأداء لكل خوارزمية بعد اختبارها على بيانات الاختبار، رتبنا هذه النتائج تصاعدياً حسب قيمة الPrecision وهو المعيار الطبي الأهم (ويظهر من الجدول أن خوارزمية الانحدار اللوجيستي كان لها الأداء الأفضل).

```
Model evaluation results:

                            Accuracy  Precision    Recall  F1-Score
Algorithm
Logistic Regression         0.982456   0.981481  0.990654  0.986047
Support Vector Machine (SVM) 0.976608  0.981308  0.981308  0.981308
k-Nearest Neighbors (KNN)   0.964912   0.954955  0.990654  0.972477
Naive Bayes                 0.935673   0.936364  0.962617  0.949309
Decision Tree               0.918129   0.934579  0.934579  0.934579
```

Figure 6 نتائج حساب معايير تقييم الأداء للخوارزميات الخمسة

Accuracy: في مسائل التصنيف الطبي يكون معيار الدقة العامة Accuracy غير دقيق (مخادع نوعاً ما) ، وينحاز باتجاه الصنف الذي يشكل معظم البيانات (في حالتنا ينحاز باتجاه الصنف الحميد الذي يشكل حوالي 62% من الأمثلة).

بالمختصر لا تعطي الدقة العامة Accuracy تنبؤاً دقيقاً بالحالات السلبية الخاطئة (False Negatives) أي يشخص الورم على أنه حميد مع إنه بالحقيقة خبيث وهو أمر بالغ الخطورة في مسائل التصنيف الطبي.

F1-score: ويعتبر من أهم معايير تقييم الأداء بالنسبة لمسائل التصنيف الطبي، يحقق التوازن المطلوب بين Precision, Recall أي تقليل كل من الإيجابيات الخاطئة (وهو أمر سلبي على المريض وعلى الأهل ويربك القطاع الصحي) والسلبيات الخاطئة (وهو أمر بالغ الخطورة حيث يتأخر مقدمو الرعاية الطبية في بدء العلاج بشكل مبكر).

مصفوفة الارتباك Confusion Matrix والخريطة الحرارية Heat Map:

تعد مصفوفة الارتباك أداة رئيسية للتقييم الشامل في مسائل التصنيف الطبي وهي تعطي فكرة موسعة حول جميع معايير التقييم والمقارنة بين القيم الحقيقية والقيم المتنبئ بها، كذلك بواسطة مكتبة Seaborn نستطيع رسم الخارطة الحرارية للمصفوفة التي تمكننا بنظرة واحدة من التعرف على طبيعة النتائج التي حصلنا عليها خلال عملية تدريب النموذج.

تقدم مكتبة sklearnطريقة جاهزة لحساب مصفوفة الارتباك، ومكتبة Seaborn وmatplotlib تقدمان طرقاً جاهزة لرسم الخريطة الحرارية ويمكن ضبط البارامترات داخل الطرق لإظهار قيم المصفوفة داخل الخريطة الحرارية.

```
from sklearn.metrics import confusion_matrix
import matplotlib.pyplot as plt
import seaborn as sns
```

رسم توضيحي 1جزء من دفتر كولاب يوضح المكتبات المستخدمة في رسم وإظهار CM

قمنا أدناه برسم مصفوفة الارتباك والخارطة الحرارية لكل خوارزمية من خوارزميات التصنيف التي درسناها على بيانات سرطان الثدي. وكانت النتائج على الشكل التالي:

Mamoun Alhamad

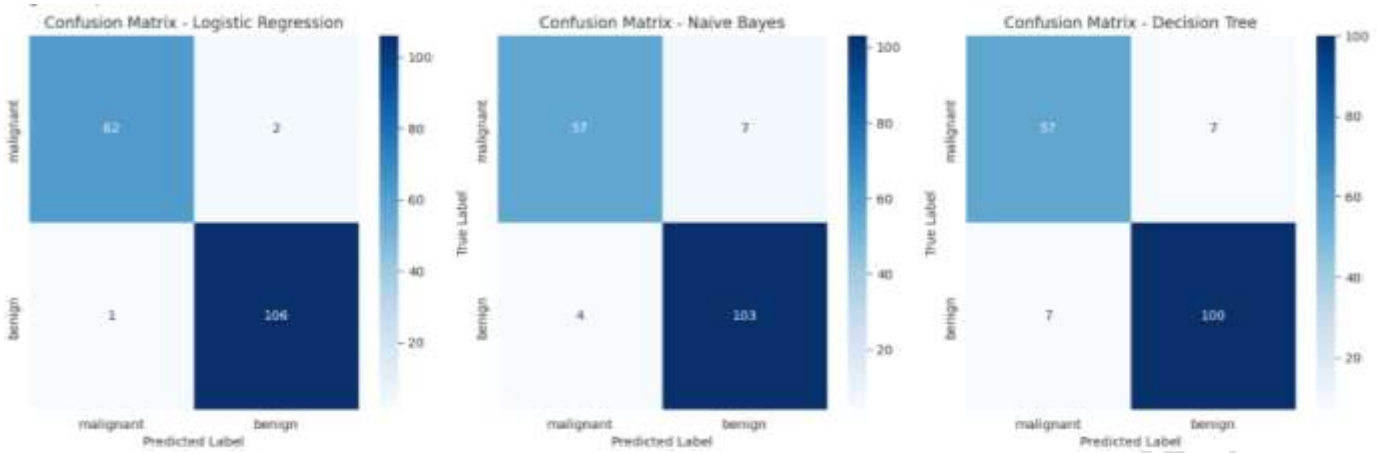

رسم توضيحي 2 مصفوفة الارتباك لكل من LR, NB, DT

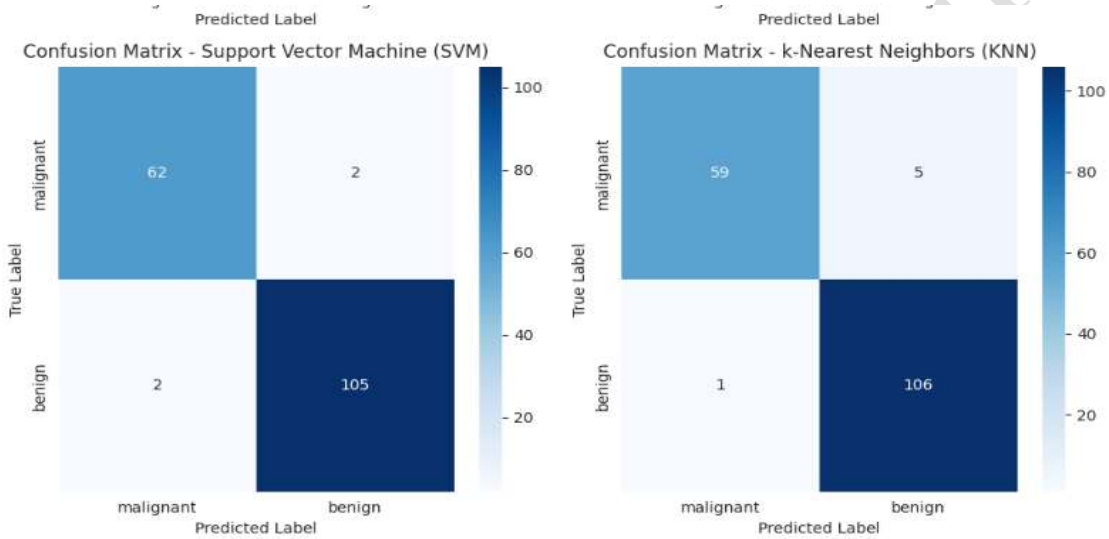

رسم توضيحي 3 مصفوفة الارتباك لكل من SVM, KNN

نلاحظ من جديد بنظرة واحدة تقارب أداء الخوارزميات ال 4 في قدرتها على تصنيف أورام الثدي مع تفوق خوارزميات الLR, KNN . الفكرة هنا الفائدة من مصفوفة الارتباك والخارطة اللونية هي مساعدتنا على تصور النتائج وإظهارها بلمحة واحدة (بالنظر إلى قطر المصفوفة).

منحنيات ROC وحساب قيمة AUC:

ROC: هو منحني بياني يوضح أداء المصنف عند جميع عتبات الفصل الممكنة Receiver Operating Characteristic، وذلك بمقارنة معدل الإيجابيات الحقيقية (True Positive Rate - TPR) على المحور الرأسي بمعدل الإيجابيات الخاطئة (False Positive Rate - FPR) على المحور الأفقي.

AUC: هي قيمة عددية تتراوح بين ال0 و ال 1 وتلخص أداء النموذج بشكل كامل وتعبر عن المساحة تحت المنحني Area Under the Curve. الفكرة تكمن في أن القيم القريبة من ال 1 تعبر عن أن النموذج يمتلك القدرة على الفصل بين الأصناف والقيم القريبة نت الصفر تشير إلى أن النموذج يفشل في الفصل بينها.

عملياً نحقق ذلك من خلال طرق خاصة وجاهزة من مكتبة sklearn ونرسم المنحنيات بواسطة matplotlib, وتتيح البارامترات المتوفرة في طرق roc_curve, roc_auc_score إمكانيات كثيرة. بالنسبة لمشروعنا سنرسم منحنيات ROC وسنضع في مربح التوضيحات legend قيم الAUC الخاصة بكل خوارزمية.

Mahmoud

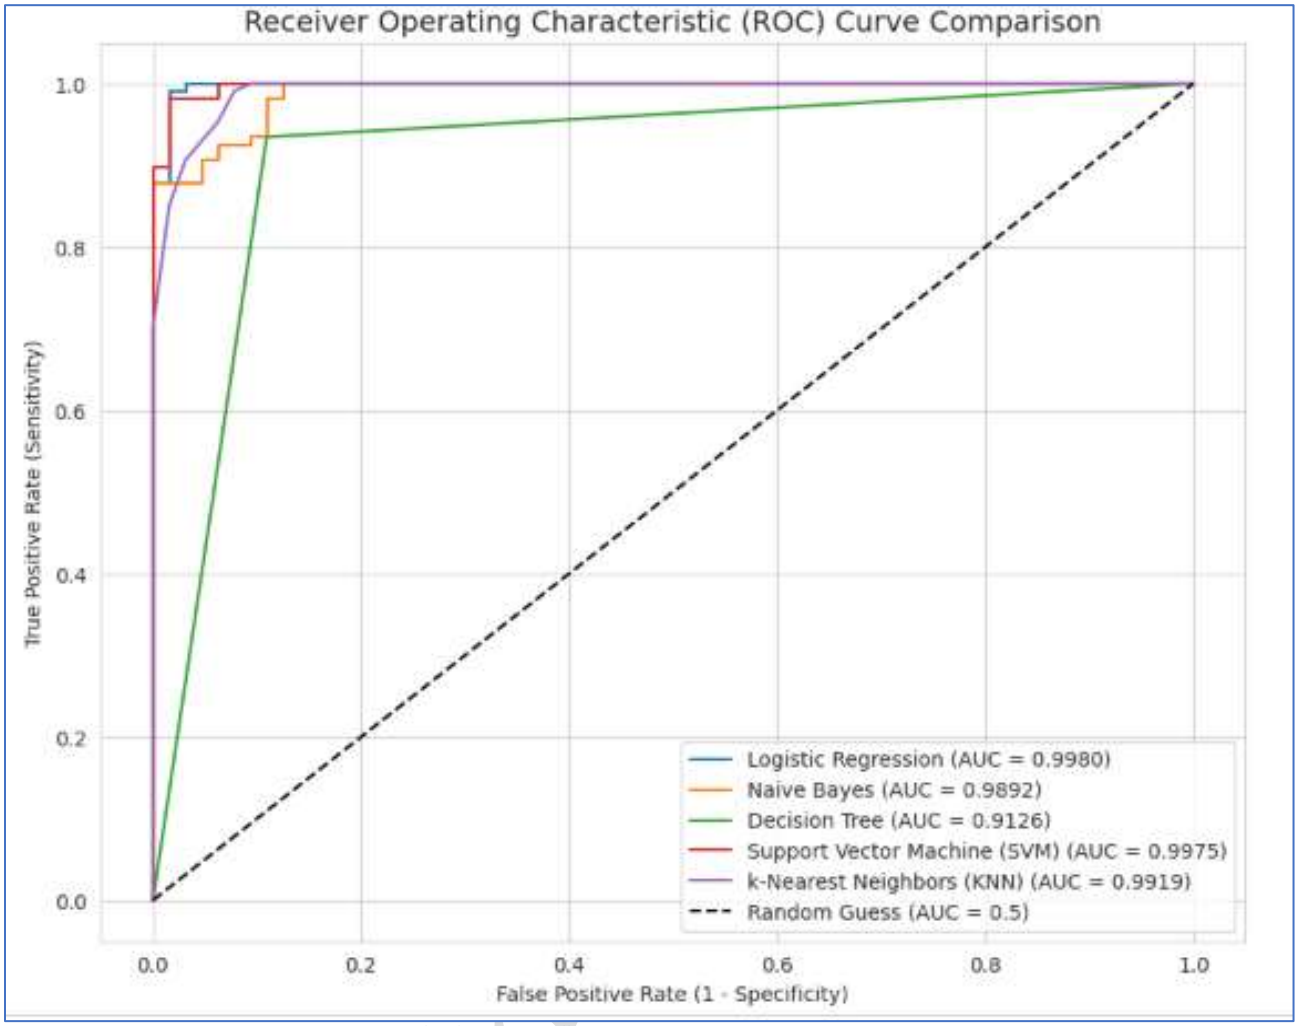

رسم توضيحي 4 مخطط ROC وقيم AUC للخوارزميات المختلفة

تحيل المخطط السابق:

يوضح ROC العلاقة بين معدل الإيجابيات الحقيقية (TPR/Recall) على المحور الرأسي ومعدل الإيجابيات الخاطئة (FPR) على المحور الأفقي عند جميع عتبات القرار الممكنة.

الفكرة هي المقايضة بين الحصول على المزيد من الإيجابيات الحقيقية وبين التضحية بقبول المزيد من الإيجابيات الخاطئة. يعد المنحنى الذي يقترب من الزاوية العلوية اليسرى (TPR=1, FPR=0) هو المصنف الأمثل الذي يمتلك قدرة فصل ممتازة بين فئات البيانات.

يبين هذا المعيار مجدداً تفوق خوارزمية الانحدار اللوجيستي بقدرتها على تصنيف الأمثلة والمقايضة Trade-off الأكثر ربحاً في التصنيف.

أما معيار ال AUC – score الذي يظهر بجانب كل خوارزمية من ال Legendيعود ويظهر اقتراب قيمة ال AUC لخوارزمية الانحدار اللوجيستي من القيمة 1 وهو يدل عل قدرتها على تصنيف الأمثلة أيضاً.

مقارنة حدود القرار باستخدام مخطط تشتت (تبعثر) وميزتين مختارتين:

بعد العودة إلى دراسات مرجعية سابقة وخبرات من أطباء شعاعيين وأطباء أورام، يعتبر هؤلاء الباحثين أن أهم

Mahmoud

ميزتين Features في تشخيص أورام الثدي هما mean radius, mean texture.

آلية العمل ستكون على الشكل التالي:

1. اختيار الميزتين السابقتين فقط.
2. إعادة تدريب نماذج من الخوارزميات الخمسة على الميزتين المذكورتين فقط.
3. إنشاء شبكة Meshgrade تغطي مجال القيم الخاصة بالميزتين السابقتين.
4. عرض حدود القرار لإظهار حدود التصنيف لكل فئة.
5. المخطط المبعثر :يتم عرض نقاط بيانات الاختبار الحقيقية (X_subset) فوق الخريطة اللونية، حيث يمثل لون النقطة التسمية الحقيقية لها(y_test) ، مما يوضح مدى صحة تصنيف كل نقطة بناءً على حد القرار.

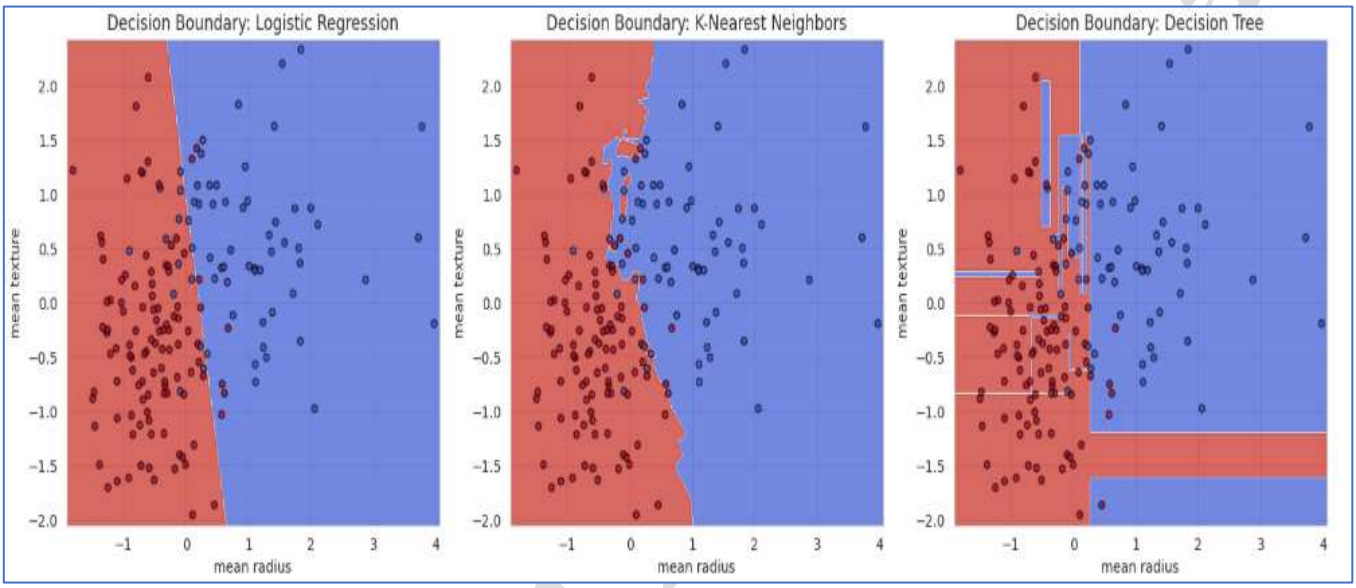

رسم توضيحي 5 مخطط التبعثر ل LR, KNN, DT

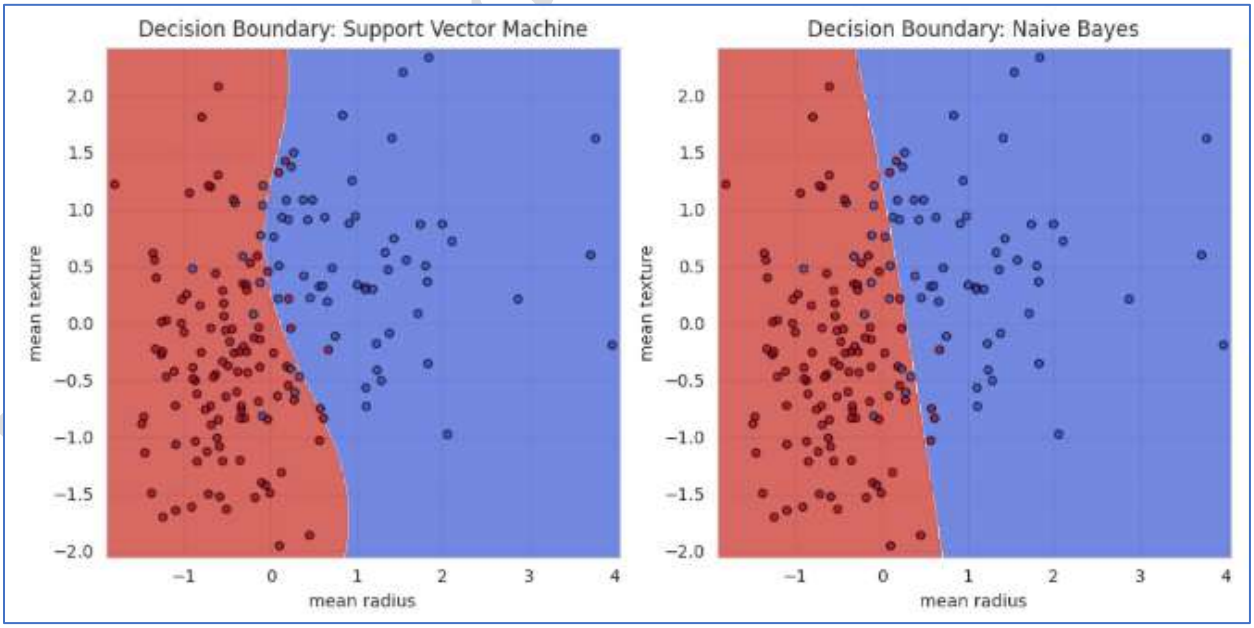

رسم توضيحي 6مخطط التبعثر ل SVM, NB

الخلاصة من المخططات السابقة:

عند تحليل سلوك المصنفات الخمسة بصرياً عبر رسم حدود القرار (Decision Boundaries) في فضاء ثنائي الأبعاد، وذلك باستخدام الميزتين السابقتين. وجدنا فروقات جوهرية بين الخوارزميات الخمسة:
حيث أظهرت خوارزميات مثل الانحدار اللوجستي (LR) حدوداً خطية ومستقيمة تفصل بين فئتي الأورام.
قدمت النماذج غير الخطية مثل SVM وDT حدوداً أكثر تعقيداً وغير منتظمة.
ما هي الخوارزميات الأفضل من هذا المنظور (البيانات غير الخطية):
خوارزمية SVM استطاعت تحقيق أعلى معدل فصل بين البيانات الموزعة بطريقة غير خطية ومتداخلة، وكان خط الفصل منتظماً وقابلاً للتحقيق.
خوارزميات ال KNN, DT نجحت بالفصل وأظهرت حدود متكسرة في حالة DT بسبب مبدأ التعتيب thresholding أثناء الفرز، أو حدود شديدة التعرج في خوارزمية KNN وذلك بسبب اعتمادها بالتصنيف على الجيران الأقرب (حدود محلية).
فشلت الخوارزميات الخطية مثل LR, NB في الفصل غير الخطي (هذا بديهي نوعاً ما).

توليف وتحسين النماذج Model Tuning:

تهدف هذه الخطوة إلى إيجاد أفضل مجموعة قيم Optimal Set للمعاملات التي لا يتم تعلمها مباشرة من البيانات مثل قيمة K في KNN أو نوع النواة Kernel في SVM. هذا يضمن أن النموذج يعمل بأقصى كفاءة ويقلل من مشكلة فرط التخصيص Overfitting أو نقص التخصيص Underfitting.
التحقيق سيتم عن طريق الصف GridSearchCV من sklearn، حيث تقوم طرق هذا الصف أوتوماتيكياً بتجريب كل تركيبة ممكنة من المعاملات الفائقة Hyper Parameters من الخوارزميات السابقة واختيار أفضل تشكيلة من هذه المعاملات.

```
from sklearn.metrics import make_scorer, f1_score
from sklearn.model_selection import GridSearchCV
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
```

رسم توضيحي 7 المكتبات والصفوف المستوردة لتنفيذ ضبط المعاملات الفائقة

بعد التنفيذ على Colab حصلنا على النتائج التالية:

```
--- Tuning Results ---
Best SVM Parameters: {'C': 0.1, 'gamma': 'scale', 'kernel': 'linear'}
Best KNN Parameters: {'metric': 'manhattan', 'n_neighbors': 3, 'weights': 'uniform'}
Best DT Parameters: {'criterion': 'gini', 'max_depth': 7, 'min_samples_leaf': 3}
```

رسم توضيحي 8 نتائج ضبط المعاملات الفائقة

نستطيع تلخيص النتائج السابقة لضبط المعاملات الفائقة كما يلي:

- SVM: نفضل عامل عقوبة صغير C أي هامش فصل واسع، وكذلك فضلنا الشكل الخطي لخط الفصل Kernal.
- KNN: اخترنا أقرب 3 جيران، طريقة حساب المسافات خوارزمية Manhattan، وتوزين منتظم للأوزان.

- DT: العمق الأقصى 7 مستويات للشجرة ، والحد الأدنى لعدد العينات المطلوبة لتكوين ورقة هو 3، أما criterion تحدد الدالة المستخدمة لقياس جودة الانقسام. وتم تحديدها ب gini.

مقارنة النماذج الأساسية مع النماذج المحسبة بواسطة مخططات ROC وقيم معامل AUC:

من خلال ROCو AUC ستكون لدينا مقارنة بصرية وعددية للخوارزميات ال 8 الناتجة حتى الآن (الخمس خوارزميات الأساسية وال 3 خوارزميات التي قمنا بتحسينها سابقاً).
سنستخدم أدوات مكتبة itertools التي ستساعدنا على تنظيم عمل الحلقات بدون استهلاك موارد ذاكرة كبيرة.
سننفذ الكود بنفس الطريقة التي رسمنا بها مخططات الROC وحسبنا بها معاملات الAUC .
سنقوم بعرض معاملات الAUC في حاشية المخطط بجانب كل خوارزمية كالعادة.
النتيجة ستكون كما يلي:

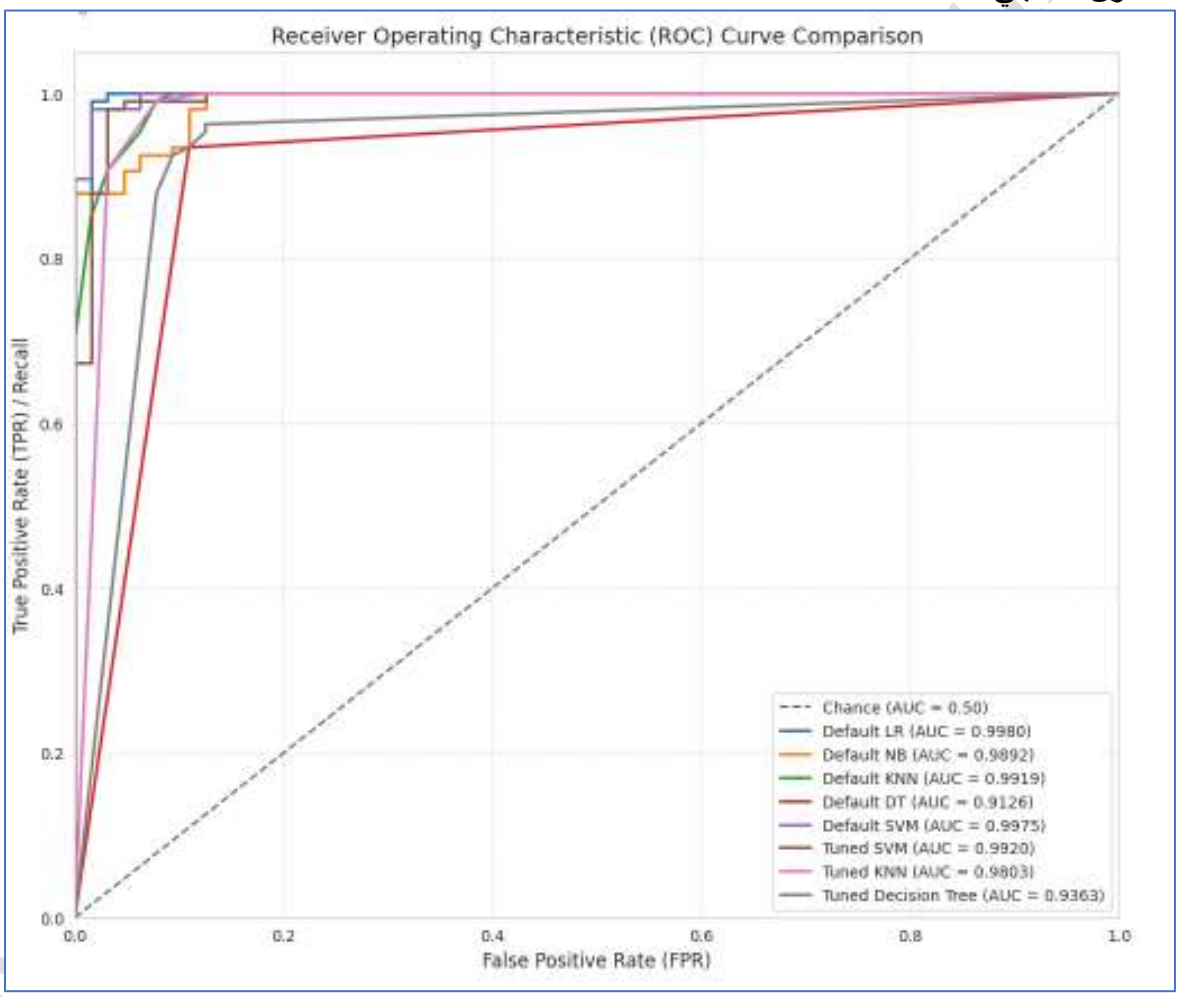

رسم توضيحي 9 مخططات ال ROC وقيم AUC للخوارزميات الثمانية

بعد ضبط المعاملات الفائقة نلاحظ تحسن أداء خوارزمية DTحيث اقترب الخط البياني ROC من الزاوية العلوية اليمنى.
أيضاً نلاحظ أن ضبط المعاملات الفائقة لخوارزمية SVM لم يؤثر كثيراً على أدائها. وكذلك خوارزمية KNN بقيت نتائجها بنفس المستوى تقريباً.

الخلاصة النهائية من المشروع ككل:

في التطبيقات الطبية، فإن الخطأ الأكثر خطورة هو السلبي الخاطئ (False Negative - FN)، أي تشخيص شخص مريض بالسرطان على أنه سليم.

منهجياً سنعتمد على قيمة ACU لاختيار الخوارزمية المناسبة لتصنيف أورام الثدي بواسطة أنماط تشخيص طبي مشابهة لأنماط التشخيص التي اتبعها الباحثون عند جمع البيانات الخاصة بمجوعة بياناتنا لمستخدمة في هذا البحث.

وحسب المعايير السابقة سنعتمد خوارزمية الانحدار اللوجيستي LR.

ولكن من وجهة نظر أخرى وعند دراستنا لحدود القرار Decision Boundaries لاحظنا أن هذه الخوارزمية – مثل كل الخوارزميات الخطية – تقوم بالفصل الخطي بين الميزات وتهمل تأثير القيم المتداخلة. بينما تقوم الخوارزميات اللاخطية مثل SVM بعملية الفصل بين هذه الأمثلة بشكل ممتاز وبدون تعقيد بالحدود. ولا بد لنا أن نذكر أن دراستنا اعتمدت على ميزتين Features فقط حدد الباحثون أنهما الأكثر تأثيراً في التصنيف.

النتيجة الخاصة بالبحث من وجهة نظرنا:

على الرغم من أن خوارزمية الانحدار اللوجيستي تفوقت على جميع الخوارزميات من ناحية المعايير التقويمية. ولكن سنفضل خوارزمية آلة شعاع الدعم SVM وذلك لاعتبارات تتعلق بطبيعة البيانات من جهة وللتقارب بين نتائج المعايير التقويمية للSVM مع ال LR.

المراجع

- كتيب الاستخدام لمجموعة البيانات الخاصة بأورام الثدي من ويسكنسن:
  Breast cancer Wisconsin (diagnostic) dataset

Mahmoud Ali Soulman